

Երևանի Պետական Համալսարան
Մաթեմատիկայի և Մեխանիկայի ֆակուլտետ
Տվյալների գիտության և վիճակագրության բաժին

Միջինացում-Մաքսիմալացում Ալգորիթմ

Հիմնական գաղափարներ, մաթեմատիկական հիմունքներ

Ուսանողներ: Լևոն Պապիկյան, Լուիզա Մուրադյան, Ռոբերտ Զաքոյան

1. Ներածություն	3
2. Միջինացում-Մաքսիմալացում ալգորիթմի ընդհանուր դեպքում.....	3
3. Գաուսյան խառնուրդ մոդել և Միջինացում-Մաքսիմալացում	5
4. K-Means.....	10
5. Գաուսյան խառնուրդ մոդելի կիրառումը MNIST տվյալների վրա.....	12

Ներածություն

Վիճակագրական գնահատումը ծառայում է որպես տարբեր ոլորտներում տվյալների վրա հիմնված որոշումների կայացման գործիք՝ սկսած գիտական հետազոտություններից մինչև բիզնեսի վերլուծություն: Այնուամենայնիվ, բացակայող կամ թաքնված փոփոխականների առկայությունը զգալի դժվարություններ է ստեղծում մոդելի պարամետրերի ճշգրիտ գնահատման և տվյալների մեկնաբանման համար: Ավանդական գնահատման մեթոդները հաճախ չեն կարողանում արդյունավետ կերպով լուծել նման բարդությունները: Նման դեպքերում Միջինացում-Մաքսիմալացում (Expectation-Maximization, EM) ալգորիթմը առաջարկում է վիճակագրական գնահատման այնպիսի մոտեցում, որը մասնակի դիտարկված տվյալների պայմաններում ցուցաբերում է լավ արդյունքներ:

EM ալգորիթմը, որն առաջին անգամ ներդրվել է Դեմփսթերի, Լայրդի և Ռուբինի կողմից 1977 թվականին, այդ ժամանակվանից դարձել է հզոր գործիք մեքենայական ուսուցման, վիճակագրության և հաշվողական կենսաբանության ոլորտներում:

EM ալգորիթմը գործում է դիտարկվող տվյալների ճշմարտանմանության ֆունկցիան մաքսիմալացնելու սկզբունքով՝ կրկնվող կերպով գնահատելով թաքնված փոփոխականների և մոդելի պարամետրերի արժեքները: Այս կրկնվող գործընթացը ներառում է երկու հիմնական քայլ՝ Միջինացում (E) քայլ և Մաքսիմալացում (M): Այս քայլերի միջև հերթափոխելով՝ EM-ն աստիճանաբար ճշգրտում է իր գնահատումները մինչև ճշմարտանմանության ֆունկցիայի մաքսիմալացումը:

Թեև EM-ը կոնցեպտուալ առումով պարզ է, կան գործնական մարտահրավերներ՝ օրինակ՝ մեծ տվյալների ծավալները կամ չափողականությունը: Այս մարտահրավերների լուծումը հաճախ ներառում է այնպիսի մեթոդների կիրառումը, ինչպիսիք են մի քանի տարբեր սկզբնական արժեքներով վերագործարկումը կամ մեծ չափողականության դեպքում, դրա նվազեցումը:

Թեև EM-ն առաջարկում է բազմաթիվ առավելություններ բացակայող տվյալների մշակման և պարամետրերի գնահատման հարցում, այլընտրանքային մեթոդները, օրինակ՝ Մարկովյան շղթայի Մոնտե Կարլոյի (MCMC) տեխնիկան, առաջարկում են վիճակագրական գնահատման լրացուցիչ մոտեցումներ և կարող են գերազանցել EM-ին որոշակի սցենարներում:

Այս գեկույցում փորձել ենք մանրամասն ներկայացնել ալգորիթմը, մաթեմատիկական հիմունքները, ինչպես նաև ներառել ենք կիրառություններ R և Python ծրագրավորման լեզուներով: Աշխատանքում հիմնականում ներկայացված են ալգորիթմի տեսական գաղափարները:

Առաջին մասում բերվում է հիմնական գաղափարը, 2-րդ մասում՝ Գաուսյան խառնուրդ մոդելի օրինակ, որտեղ կիրառվում է Միջինացում-Մաքսիմալացում ալգորիթմը, 3-րդ մասում Գաուսյան խառնուրդ մոդելում կիրառված EM ալգորիթմի Մաքսիմալացում քայլից դուրս է բերվում K-Means ալգորիթմը, իսկ 4-րդ մասում բերվում է ալգորիթմի կիրառումը MNIST տվյալների վրա:

Միջինացում-Մաքսիմալացում ալգորիթմը ընդհանուր դեպքում

Միջինացում-Մաքսիմալացում ալգորիթմը սովորաբար նկարագրվում է որպես երկու քայլ (E-քայլ և M-քայլ), բայց մենք կփոփոխենք այն բաժանել չորս քայլի. Դիցուք տրված է համատեղ բաշխում $p(X, Z | \theta)$, $X = (X_1, \dots, X_N)$ պատահական նմուշի և $Z = (Z_1, \dots, Z_M)$ անհայտ փոփոխականների համար, որոնք ևս պատահական մեծություններ են: Նպատակն է գտնել $p(X|\theta)$ ճշմարտանմանության ֆունկցիայի մաքսիմումը:

$$\ln p(X|\theta) = \ln \left[\sum_Z p(X, Z | \theta) \right]$$

Նկատենք, որ նույնիսկ այն դեպքում երբ, համատեղ բաշխման ֆունկցիան էքսպոնենտական ընտանիքից է, գումարի պատճառով $\ln p(X|\theta)$ -ն չի լինի էքսպոնենտական ընտանիքից, որը բավականին բարդացնում է լոգարիթմական-ճշմարտանմանության ֆունկցիայի ուղղակի մաքսիմալացումը:

Այդ իսկ պատճառով կդիտարկենք Միջինացում-Մաքսիմալացում ալգորիթմը:

1. ընտրենք նախնական արժեքներ θ^{old}
2. Հաշվի առնելով դիտարկված տվյալները՝ x , և կիրառելով մեր նախնական արժեք՝ θ^{old} -ը, դիտարկենք պայմանական բաշխումը՝ $p(Z|x, \theta^{old})$
3. Օգտագործելով 2-րդ քայլում հաշվարկված $p(Z|x, \theta^{old})$ պայմանական բաշխումը, ձևավորենք պայմանական մաթեմատիկական սպասումը, որը կոչվում է Q-ֆունկցիա.

$$Q(\theta|\theta^{old}) = E(\ln p(X, Z|\theta) | x, \theta^{old}) = \sum_Z p(Z|x, \theta^{old}) \ln p(X, Z|\theta)$$

Գտնենք այն θ -ն, որը առավելագույնի է հասցնում Q-ֆունկցիան, արդյունքը մեր նոր գնահատականն է θ^{new} .

$$\theta^{new} = \operatorname{argmax}_{\theta} Q(\theta|\theta^{old})$$

4. Ստուգենք, արդյոք ունենք զուգամիտություն ճշմարտանմանության ֆունկցիայի կամ պարամետրերի արժեքների համար: Եթե զուգամիտության պայմանները բավարարված չեն, ապա՝

$$\theta^{old} \leftarrow \theta^{new}$$

և վերադառնանք քայլ 2:

Ալգորիթմը չի սահմանում դադարեցման պայմանները: Մեր կողմից տրված պայմանները պետք է կրկնվեն այնքան ժամանակ, մինչև դրանք կբավարարվեն:

Օրինակ՝ $|l(\theta^{old}) - l(\theta^{new})| < \epsilon$ կամ $|\theta^{old} - \theta^{new}| < \epsilon$, ֆիքսված $\epsilon > 0$:

Միջինացում-Մաքսիմալացում գնահատականը միայն երաշխավորված է, որ երբեք չի վատանա:

Սովորաբար, այն կգտնի $p(X|\theta)$ ճշմարտանմանության ֆունկցիայի մաքսիմումը, բայց եթե $p(X|\theta)$ ճշմարտանմանության ֆունկցիան ունի մի քանի լոկալ մաքսիմումներ, Միջինացում-Մաքսիմալացումը կարող է չգտնել գլոբալ մաքսիմում արժեքը: Գործնականում կարելի է ալգորիթմը սկսել մի քանի պատահական սկզբնական արժեքներով անհայտ պարամետրերի համար և ընտրել մեծագույն արժեք ունեցող ճշմարտանմանության ֆունկցիայով գնահատականները որպես վերջնական գուշակություն θ -ի համար:

Միջինացում-Մաքսիմալացում ալգորիթմի ավանդական նկարագրությունը բաղկացած է ընդամենը երկու քայլից.

1. **E-քայլ** Հաշվի առնելով նախորդ կրկնությունից θ^{old} գնահատականը, հաշվարկենք պայմանական մաթեմատիկական սպասումը $Q(\theta|\theta^{old})$
2. **M-քայլ** θ^{new} հետևյալն է.

$$\theta^{new} = \operatorname{argmax}_{\theta} Q(\theta|\theta^{old})$$

Գաուսյան խառնուրդ մոդել և Միջինացում-Մաքսիմալացում

Այս բաժնում մենք կքննարկենք պարզ խառնուրդ մոդել (mixture model)՝ խտության ֆունկցիայի գնահատականի համար, և կից Միջինացում-Մաքսիմալացում ալգորիթմը՝ ճշմարտանմանության ֆունկցիան մաքսիմիզացնելու համար:

Նախ եկեք գեներացնենք տվյալներ R լեզվով: Դիտարկենք 0.2 հավանականությամբ բինոմական բաշխված $C_1, \dots, C_{10000}$ պատահական մեծությունների հաջորդականություն:

$$C_1, \dots, C_{10000} \sim \text{Bin}(0.2)$$

Դիտարկենք նաև մեկ այլ պատահական մեծությունների հաջորդականություն՝ $\beta_1, \dots, \beta_{10000}$,

$$\beta_i = \begin{cases} \eta \sim N(-12, 3^2), & C_i = 1 \\ \zeta \sim N(2, 1), & C_i = 0 \end{cases}$$


R լեզվով հաջորդաբար (համապատասխանաբար) գեներացնենք C_i β_i պատահական մեծությունների $C_1, \dots, C_{10000}$, $\gamma_1, \dots, \gamma_{10000}$ թվային նմուշները:

```
# Generate binomial samples
binomial_samples <- rbinom(10000, size = 1, prob = 0.2)

# Initialize an empty vector to store the generated values
datapoints <- numeric(length(binomial_samples))

# Generate values based on binomial samples
for (i in seq_along(binomial_samples)) {
  if (binomial_samples[i] == 1) {
    datapoints[i] <- rnorm(1, mean = -12, sd = 3)
  } else {
    datapoints[i] <- rnorm(1, mean = 2, sd = 1)
  }
}
```

Կազմելով նմանատիպ տվյալների խումբ, եկեք ենթադրենք, որ նորմալ բաշխումների միջինների ու վարիացիաների ինֆորմացիան կորցրել ենք:



Մենք ցանկանում ենք մոդելավորել մեզ տրված տվյալների խտությունը, և ակնհայտ երկմոդալության պատճառով Գաուսյան բաշխումը տեղին չի լինի: Գիտեք, որ հիմքում կան ընկած երկու առանձին ռեժիմներ, ուստի փոխարենը մենք կմոդելավորենք Y -ը որպես երկու նորմալ բաշխումների խառնուրդ.

$$Y_1 \sim N(\mu_1, \sigma_1^2)$$

$$Y_2 \sim N(\mu_2, \sigma_2^2)$$

$$Y = (1 - \Delta) \cdot Y_1 + \Delta \cdot Y_2$$

որտեղ $\Delta \in \{0,1\}$ $P(\Delta = 1) = p$ անհայտ հավանականությամբ: Y բաշխումից կամայական Y_i պատահական մեծությանը կհամապատասխանի Δ_i պատահական մեծություն:

Հիմա ենթադրենք, որ մենք ցանկանում ենք առավելագույն հավանականությամբ այս մոդելը համապատասխանեցնել մեր տվյալներին: Պարամետրերն են՝

$$\theta = (p, \theta_1, \theta_2) = (p, \mu_1, \sigma_1^2, \mu_2, \sigma_2^2)$$

N դեպքերի վրա հիմնված լոգարիթմական-ճշմարտանմանության ֆունկցիան՝

$$L(\theta; X) = \sum_N \log[(1 - p)\varphi_{\theta_1}(y_i) + p\varphi_{\theta_2}(y_i)]$$

Որտեղ $\varphi_{\theta_1}(y), \varphi_{\theta_2}(y)$ համապատասխանաբար Y_1, Y_2 -ի բաշխման ֆունկցիաններն են: $L(\theta; X)$ -ի ուղղակի մաքսիմալացումը թվային առումով բավականին դժվար է, լոգարիթմի ներսում գումարի պատճառով: Սակայն, կա ավելի պարզ մոտեցում. Մենք հաշվի ենք առնում չդիտարկված, թաքնված (latent) փոփոխականները Δ_i ՝ դիտարկելով 0 կամ 1 արժեքները, քանի որ եթե $\Delta_i = 1$, ապա y_i -ն գալիս է 2-րդ մոդելից, հակառակ դեպքում այն գալիս է մոդել 1-ից: Ենթադրենք, որ մենք գիտեինք Δ_i -ի արժեքները: Այդ դեպքում լոգարիթմական-ճշմարտանմանության ֆունկցիան կլինի հետևյալ տեսքի՝

$$\begin{aligned} L(\theta; X, \Delta) &= \sum_{k=1}^N l_0(\theta; X = y_k, \Delta_k) = \\ &= \sum_{k=1}^N [(1 - \Delta_k) \log(\varphi_{\theta_1}(y_k)) + \Delta_k \log(\varphi_{\theta_2}(y_k))] + \sum_{k=1}^N [(1 - \Delta_k) \log(1 - p) + \Delta_k \log(p)] \end{aligned}$$

Եկեք նշանակենք $l_0(\theta; X = y_k, \Delta_k) := [(1 - \Delta_k) \log(1 - p) + \Delta_k \log(p)] + [(1 - \Delta_k) \log(\varphi_{\theta_1}(y_k)) + \Delta_k \log(\varphi_{\theta_2}(y_k))]$ հետագա քայլերի համար:

μ_1, σ_1^2 -ի մաքսիմում ճշմարտանմանության գնահատականները կլինեն նմուշի՝ $\Delta_i = 0$ խմբի, միջինը և դիսպերսիան, և նմանապես μ_2, σ_2^2 -ի համար գնահատականները կլինեն նմուշի միջինը և դիսպերսիան $\Delta_i = 1$ -ով տվյալների խմբի համար: p -ի Գնահատականը կլինի՝

$$\frac{\partial L(\theta; X, \Delta)}{\partial p} = \frac{-\sum_{i=1}^N (1 - \Delta_i)}{1 - p} + \frac{\sum_{i=1}^N \Delta_i}{p} = 0$$

$$\frac{1}{(1 - p)p} \sum_{i=1}^N ((\Delta_i - 1)p + \Delta_i(1 - p)) = 0$$

$$\hat{p} = \frac{\sum_{i=1}^N \Delta_i}{N}$$

Քանի որ Δ_i -ի արժեքներն իրականում անհայտ են, մենք կշարունակենք այլ եղանակով՝ փոխարինելով յուրաքանչյուր Δ_i -ին իր մաթեմատիկական սպասման արժեքով:

$$\begin{aligned}\gamma_i(\theta) &= E(\Delta_i | \theta, X) = \sum_{k=0}^1 k P(\Delta_i = k | \theta, X) \\ &= 0 P(\Delta_i = 0 | \theta, X) + 1 P(\Delta_i = 1 | \theta, X) = \\ &= 1 P(\Delta_i = 1 | \theta, X) = \frac{P(\Delta_i = 1) P(\theta, X | \Delta_i = 1)}{P(\theta, X)} = \frac{p \varphi_{\theta_2}(y_i)}{(1-p) \varphi_{\theta_1}(y_i) + p \varphi_{\theta_2}(y_i)} \\ \gamma_i(\theta) &= \frac{p \varphi_{\theta_2}(y_i)}{(1-p) \varphi_{\theta_1}(y_i) + p \varphi_{\theta_2}(y_i)}\end{aligned}$$

$\gamma_i(\theta)$ – ն կոչվում է նաև 2-րդ մոդելի պատասխանատվությունը y_i – ի համար. Մենք օգտագործում ենք EM ալգորիթի ընթացակարգը, Գաուսի խառնուրդների հատուկ դեպքի համար: Միջինացում (Expectation) քայլում մենք յուրաքանչյուր y_i -ի համար կատարում ենք soft assignment, դիտարկում ենք y_i -ի 1-ին ու 2-րդ մոդելներին պատկանելու հավանականությունները: Մաքսիմալացման քայլում այս $\gamma_i(\theta)$ օգտագործվում են $Q(\theta, \theta^{old})$ ֆունկցիայի պարամետրերի գնահատումները թարմացնելու համար: μ_1^2, μ_2^2 -ի համար սկզբնական արժեքներ կառուցելու լավ միջոց է պարզապես պատահականորեն ընտրել երկուսը y_i -ից: Ինչպես σ_1^2 , այնպես էլ σ_2^2 -ի գնահատականները կարող են հավասար լինել թվային նմուշի ընդհանուր շեղմանը: Ի գնահատումը կարող է սկսվել 0,5 արժեքից: Հիմա կառուցենք $Q(\theta, \theta^{old})$ ֆունկցիան մաքսիմալացման քայլի համար:

$$Q(\theta, \theta^{old}) = E(L(\theta; X, \Delta) | \theta^{old}, X = y)$$

$$\text{Որտեղ } y = (y_1, \dots, y_n) \quad \theta^{old} = (p^{old}, \theta_1^{old}, \theta_2^{old})$$

$$\begin{aligned}E(L(\theta; X, \Delta) | \theta^{old}, X = y) &= \sum_{k=1}^N E(l_0(\theta; y_k, \Delta_k) | \theta^{old}, X = y_k) = \\ &= \sum_{k=1}^N \sum_{\Delta_k=0,1} P(\Delta_k | \theta^{old}, X = y_k) l_0(\theta; y_k, \Delta_k) \\ &= \sum_{k=1}^N \sum_{\Delta_k=0,1} P(\Delta_k | \theta^{old}, X = y_k) \left[((1 - \Delta_k) \log(\phi_{\theta_1}(y_k)) + \Delta_k \log(\phi_{\theta_2}(y_k))) \right. \\ &\quad \left. + ((1 - \Delta_k) \log(1 - p) + \Delta_k \log(p)) \right] = \\ &= \sum_{k=1}^N (1 - \gamma_k(\theta^{old})) (\log(\phi_{\theta_1}(y_k)) + \log(1 - p)) + \sum_{k=1}^N \gamma_k(\theta^{old}) (\log(\phi_{\theta_2}(y_k)) + \log(p))\end{aligned}$$

Հիմա դիտարկենք $Q(\theta, \theta^{old})$ ֆունկցիայի ածանցյալը ըստ p -ի

$$\begin{aligned}
\frac{\partial Q}{\partial p} &= \sum_{k=1}^N (1 - \gamma_k(\theta^{old})) \frac{-1}{1-p} + \sum_{k=1}^N \gamma_k(\theta^{old}) \frac{1}{p} = 0 \\
\frac{-p \sum_{k=1}^N (1 - \gamma_k(\theta^{old})) + (1-p) \sum_{k=1}^N \gamma_k(\theta^{old})}{(1-p)p} &= 0 \\
-p \sum_{k=1}^N 1 + p \sum_{k=1}^N \gamma_k(\theta^{old}) + \sum_{k=1}^N \gamma_k(\theta^{old}) - p \sum_{k=1}^N \gamma_k(\theta^{old}) &= 0 \\
pN &= \sum_{k=1}^N \gamma_k(\theta^{old}) \\
p &= \frac{\sum_{k=1}^N \gamma_k(\theta^{old})}{N}
\end{aligned}$$

p -ի գնահատականը ստացվեց $\hat{p} = \frac{\sum_{k=1}^N \gamma_k(\theta^{old})}{N}$

Դիտարկենք $Q(\theta, \theta^{old})$ ֆունկցիայի ածանցյալը ըստ μ_1 - ի

$$\begin{aligned}
\frac{\partial Q}{\partial \mu_1} &= \sum_{k=1}^N (1 - \gamma_k(\theta^{old})) \left(\frac{-(y_k - \mu_1)}{\sigma_1^2} \right) = 0 \\
\sum_{k=1}^N (1 - \gamma_k(\theta^{old})) (y_k - \mu_1) &= 0 \\
\sum_{k=1}^N (1 - \gamma_k(\theta^{old})) y_k - \sum_{k=1}^N (1 - \gamma_k(\theta^{old})) \mu_1 &= 0 \\
\sum_{k=1}^N (1 - \gamma_k(\theta^{old})) y_k &= \sum_{k=1}^N (1 - \gamma_k(\theta^{old})) \mu_1 \\
\mu_1 &= \frac{\sum_{k=1}^N (1 - \gamma_k(\theta^{old})) y_k}{\sum_{k=1}^N (1 - \gamma_k(\theta^{old}))}
\end{aligned}$$

μ_1 -ի գնահատականը ստացվեց $\hat{\mu}_1 = \frac{\sum_{k=1}^N (1 - \gamma_k(\theta^{old})) y_k}{\sum_{k=1}^N (1 - \gamma_k(\theta^{old}))}$

Համապատասխանաբար մյուս պարամետրերի գնահատականները կստացվի՝

$$\frac{\partial Q}{\partial \mu_2} = \widehat{\mu}_2 = \frac{\sum_i^N \hat{\gamma}_i y_i}{\sum_i^N \hat{\gamma}_i}$$

$$\frac{\partial Q}{\partial \sigma^2_1} = \widehat{\sigma^2_1} = \frac{\sum_i^N (1 - \hat{\gamma}_i)(y_i - \widehat{\mu}_1)^2}{\sum_i^N (1 - \hat{\gamma}_i)} \quad \frac{\partial Q}{\partial \sigma^2_2} = \widehat{\sigma^2_2} = \frac{\sum_i^N \hat{\gamma}_i (y_i - \widehat{\mu}_2)^2}{\sum_i^N \hat{\gamma}_i}$$

EM ալգորիթմը 2-կոմպոնենտով Գաուսյան խառնուրդ-ի համար.

1. Դիտարկել սկզբնական արժեքները $\widehat{\mu}_1, \widehat{\mu}_2, \widehat{\sigma^2_1}, \widehat{\sigma^2_2}, \hat{p}$
2. Միջինացման քայլ. Հաշվել պատասխանատվությունները

$$\hat{\gamma}_i(\theta) = \frac{\hat{p}\varphi_{\theta_2}(y_i)}{(1 - \hat{p})\varphi_{\theta_1}(y_i) + \hat{p}\varphi_{\theta_2}(y_i)} \quad i = 1, 2, \dots, N$$

3. Մաքսիմալացման քայլ. Հաշվել կշռավորված միջինները ու վարիացիաները:

$$\frac{\partial Q}{\partial \mu_1} = \widehat{\mu}_1 = \frac{\sum_i^N (1 - \hat{\gamma}_i) y_i}{\sum_i^N (1 - \hat{\gamma}_i)} \quad \frac{\partial Q}{\partial \mu_2} = \widehat{\mu}_2 = \frac{\sum_i^N \hat{\gamma}_i y_i}{\sum_i^N \hat{\gamma}_i}$$

$$\frac{\partial Q}{\partial \sigma^2_1} = \widehat{\sigma^2_1} = \frac{\sum_i^N (1 - \hat{\gamma}_i)(y_i - \widehat{\mu}_1)^2}{\sum_i^N (1 - \hat{\gamma}_i)} \quad \frac{\partial Q}{\partial \sigma^2_2} = \widehat{\sigma^2_2} = \frac{\sum_i^N \hat{\gamma}_i (y_i - \widehat{\mu}_2)^2}{\sum_i^N \hat{\gamma}_i}$$

$$\text{և խառնուրդային հավանականությունը } \frac{\partial Q}{\partial p} = \hat{p} = \sum_i^N \hat{\gamma}_i / N$$

4. կրկնել քայլ 2 ու 3 -ը մինչև զուգամիտություն

Մեր ունեցած տվյալների վրա R լեզվով Գաուսյան խառնուրդ մոդելը աշխատեցնելուց, ստացվեց հետևյալ արդյունքը՝

```
fitting ...
|=====| 100%
Iteration 1 : Mixing Proportions = 0.2014176 0.7985824
Iteration 1 : Mean Estimations = -12.07024 1.988329
Iteration 1 : Variance Estimations = 9.177795 0.9984295
fitting ...
|=====| 100%
Iteration 2 : Mixing Proportions = 0.2014175 0.7985825
Iteration 2 : Mean Estimations = -12.07025 1.988329
Iteration 2 : Variance Estimations = 9.177716 0.9984315
fitting ...
|=====| 100%
Iteration 3 : Mixing Proportions = 0.2014177 0.7985823
Iteration 3 : Mean Estimations = -12.07024 1.98833
Iteration 3 : Variance Estimations = 9.177817 0.998429
fitting ...
|=====| 100%
Iteration 4 : Mixing Proportions = 0.2014175 0.7985825
Iteration 4 : Mean Estimations = -12.07025 1.988329
Iteration 4 : Variance Estimations = 9.177721 0.9984314
fitting ...
|=====| 100%
Iteration 5 : Mixing Proportions = 0.2014177 0.7985823
Iteration 5 : Mean Estimations = -12.07024 1.98833
Iteration 5 : Variance Estimations = 9.177828 0.9984287
```

Վերջնական ճշմարտանմանության մաքսիմում մեթոդի գնահատականներն են՝
 $\widehat{\mu}_1 = -12.07024$ $\widehat{\mu}_2 = 1.98833$ $\widehat{\sigma^2_1} = 9.177828$ $\widehat{\sigma^2_2} = 0.9984287$ $\hat{p} = 0.2014176$

K-Means

K-means ալգորիթմի ու Գաուսի խառնուրդների EM ալգորիթմի միջև կա մոտ նմանություն: Մինչ K-means-ը կատարում է տվյալների կետերի hard assignment կլաստերներին՝ կետին

համապատասխանեցնելով մեկ կլաստեր, EM ալգորիթմը ապահովում է soft assignment՝ կետին տալով յուրաքանչյուր կլաստերին պատկանելու հավանականություն:

Մենք կարող ենք դուրս բերել K-means ալգորիթմը որպես EM-ի հատուկ դեպք Գաուսի խառնուրդների համար: Դիտարկենք $\phi_{\theta_1}(y_k), \phi_{\theta_2}(y_k)$ բաշխման ֆունկցիաները դիտարկելով $\sigma_1^2 = \sigma_2^2 = \sigma^2$, որտեղ σ^2 -ին ինչ-որ ֆիքսված հաստատուն է՝

$$\phi_{\theta_1}(y_k) = \frac{1}{\sqrt{(2\pi\sigma^2)}} \exp\left(-\frac{1}{2\sigma^2} |y_k - \mu_1|^2\right)$$

$$\phi_{\theta_2}(y_k) = \frac{1}{\sqrt{(2\pi\sigma^2)}} \exp\left(-\frac{1}{2\sigma^2} |y_k - \mu_2|^2\right)$$

σ^2 -ուն որպես հաստատուն վերաբերվելով, կետին տրված պատասխանատվություն $\gamma_i(\theta)$ -երն ընդունում են հետևյալ տեսքը՝

$$\gamma_i(\theta) = \frac{p \frac{1}{\sqrt{(2\pi\sigma^2)}} \exp\left(-\frac{1}{2\sigma^2} |y_k - \mu_2|^2\right)}{(1-p) \frac{1}{\sqrt{(2\pi\sigma^2)}} \exp\left(-\frac{1}{2\sigma^2} |y_k - \mu_1|^2\right) + p \frac{1}{\sqrt{(2\pi\sigma^2)}} \exp\left(-\frac{1}{2\sigma^2} |y_k - \mu_2|^2\right)}$$

$$= \frac{p \exp\left(-\frac{1}{2\sigma^2} |y_k - \mu_2|^2\right)}{(1-p) \exp\left(-\frac{1}{2\sigma^2} |y_k - \mu_1|^2\right) + p \exp\left(-\frac{1}{2\sigma^2} |y_k - \mu_2|^2\right)}$$

Եկեք դիտարկենք հետևյալ r_i ֆունկցիան՝

$$r_i = \begin{cases} 1, & |y_i - \mu_2|^2 < |y_i - \mu_1|^2 \\ 0, & |y_i - \mu_2|^2 > |y_i - \mu_1|^2 \end{cases}$$

Այսինքն երբ r_i ֆունկցիան ընդունում է 1 արժեքը, նշանակում է որ y_i կետը ավելի մոտ է μ_2 միջինին:

Ցույց տանք որ $\gamma_i(\theta)$ սահմանը երբ $\sigma^2 \rightarrow 0$ կստացվի հենց r_i : Դիտարկենք 2 դեպք՝

1. $|y_i - \mu_2|^2 < |y_i - \mu_1|^2$ նշանակենք $|y_k - \mu_2|^2 - |y_k - \mu_1|^2 := -c_1$ $c_1 > 0$

$$\gamma_i(\theta) = \frac{p \exp\left(-\frac{1}{2\sigma^2} |y_k - \mu_2|^2\right)}{p \exp\left(-\frac{1}{2\sigma^2} |y_k - \mu_2|^2\right) + (1-p) \exp\left(-\frac{1}{2\sigma^2} |y_k - \mu_1|^2\right)}$$

$$= \frac{1}{\frac{(1-p) \exp\left(-\frac{1}{2\sigma^2} |y_k - \mu_1|^2\right)}{p \exp\left(-\frac{1}{2\sigma^2} |y_k - \mu_2|^2\right)} + 1} = \frac{1}{\frac{(1-p) \exp\left(\frac{-c_1}{2\sigma^2}\right)}{p} + 1}$$

$$\lim_{\sigma^2 \rightarrow 0} \frac{1}{\frac{(1-p)}{p} \exp\left(\frac{-c_1}{2\sigma^2}\right) + 1} = 1$$

2. $|y_i - \mu_2|^2 > |y_i - \mu_1|^2$ դեպքում քայլերը կատարվում է նույն տրամաբանությամբ և ստացվում՝

$$\lim_{\sigma^2 \rightarrow 0} \gamma_i(\theta) = 0$$

Այսպիսով, այս սահմանում մենք ստանում ենք տվյալների hard assignment կլաստերներին, Յուրաքանչյուր կետ վերագրվում է ամենամոտ միջինին ունեցող կլաստերին:

Դիտարկենք $\lim_{\sigma \rightarrow 0} \sigma^2 E(L(\theta; X, \Delta) | \theta^{old}, X = y)$ սահմանը:

$$\begin{aligned} \lim_{\sigma \rightarrow 0} \sigma^2 E(L(\theta; X, \Delta) | \theta^{old}, X = y) &= \lim_{\sigma \rightarrow 0} \sigma^2 \left(\sum_{k=1}^N (1 - \gamma_k(\theta^{old})) \left(\log \left(\frac{1}{\sqrt{(2\pi\sigma^2)}} \exp \left(-\frac{1}{2\sigma^2} |y_k - \mu_1|^2 \right) \right) + \right. \right. \\ &\quad \left. \left. \log(1 - p) \right) + \sum_{k=1}^N \gamma_k(\theta^{old}) \left(\log \left(\frac{1}{\sqrt{(2\pi\sigma^2)}} \exp \left(-\frac{1}{2\sigma^2} |y_k - \mu_2|^2 \right) \right) + \log(p) \right) \right) = \lim_{\sigma \rightarrow 0} \sigma^2 \left(\sum_{k=1}^N (1 - \right. \\ &\quad \left. \gamma_k(\theta^{old})) \left(\log \left(\frac{1}{\sqrt{(2\pi\sigma^2)}} \right) - \frac{1}{2\sigma^2} |y_k - \mu_1|^2 + \log(1 - p) \right) + \sum_{k=1}^N \gamma_k(\theta^{old}) \left(\log \left(\frac{1}{\sqrt{(2\pi\sigma^2)}} \right) - \frac{1}{2\sigma^2} |y_k - \mu_2|^2 + \right. \right. \\ &\quad \left. \left. \log(p) \right) \right) = \lim_{\sigma \rightarrow 0} \sigma^2 \left(\sum_{k=1}^N (1 - \gamma_k(\theta^{old})) \log \left(\frac{1}{\sqrt{(2\pi\sigma^2)}} \right) - \sum_{k=1}^N (1 - \gamma_k(\theta^{old})) \frac{1}{2\sigma^2} |y_k - \mu_1|^2 + \right. \\ &\quad \left. \sum_{k=1}^N (1 - \gamma_k(\theta^{old})) \log(1 - p) + \sum_{k=1}^N \gamma_k(\theta^{old}) \log \left(\frac{1}{\sqrt{(2\pi\sigma^2)}} \right) - \sum_{k=1}^N \gamma_k(\theta^{old}) \frac{1}{2\sigma^2} |y_k - \mu_2|^2 + \right. \\ &\quad \left. \sum_{k=1}^N \gamma_k(\theta^{old}) \log(p) \right) = \lim_{\sigma \rightarrow 0} \sigma^2 \left(N \log \left(\frac{1}{\sqrt{(2\pi\sigma^2)}} \right) - \sum_{k=1}^N (1 - \gamma_k(\theta^{old})) \frac{1}{2\sigma^2} |y_k - \mu_1|^2 + \sum_{k=1}^N (1 - \right. \\ &\quad \left. \gamma_k(\theta^{old})) \log(1 - p) - \sum_{k=1}^N \gamma_k(\theta^{old}) \frac{1}{2\sigma^2} |y_k - \mu_2|^2 + \sum_{k=1}^N \gamma_k(\theta^{old}) \log(p) \right) = -\frac{1}{2} \sum_{k=1}^N (1 - r_k) |y_k - \mu_1|^2 - \\ &\quad \frac{1}{2} \sum_{k=1}^N r_k |y_k - \mu_2|^2 + const \end{aligned}$$


Այսինքն ստացվեց՝

$$\lim_{\sigma \rightarrow 0} \sigma^2 E(L(\theta; X, \Delta) | \theta^{old}, X = y) = -\frac{1}{2} \sum_{k=1}^N (1 - r_k) |x_k - \mu_2|^2 - \frac{1}{2} \sum_{k=1}^N r_k |x_k - \mu_1|^2 + const$$

Այսպիսով Գաուսյան խառնուրդ մոդելում EM ալգորիթմի Q ֆունկցիայի սահմանը՝ K-Means ալգորիթմում օգտագործվող, այն կարևոր ֆունկցիան է, որը չափում է կետերի և փնտրվող միջինների միջև հեռավորությունը ամեն իտերացիայում:

Գաուսյան խառնուրդ մոդելի կիրառումը MNIST տվյալների վրա

Այս բաժնում կուսուժասիրենք MNIST տվյալների հավաքածուն և կփորձենք կիրառել Գաուսյան խառնուրդ մոդելը: MNIST տվյալների հավաքածուն բաղկացած է երկու մասից՝ ուսուցանող (train) հավաքածու, որը բաղկացած է 60,000 նկարներից և թեստային (test) հավաքածուն իր 10,000 նկարներով: Յուրաքանչյուր տող պարունակում է նկարի պիտակը (label) և pixel ինֆորմացիան՝ ընդհանուր 785 սյունով: Տվյալների հավաքածուն ներկայացնում է ձեռագիր թվերի պատկերների հավաքածու:



Սկզբում կդիտարկենք clustering-ի խնդիր: Այս գործընթացի ընթացքում մեր հիմնական խնդիրներից մեկը տվյալների բարձր չափողականությունն է, ուստի կկատարենք չափողականության նվազեցում՝ օգտագործելով PCA: Քանի որ աշխատում ենք պատկերների հետ, տվյալների նորմավորումը (բաժանում 255-ի վրա) կարևոր քայլ է: Քանի որ ունենք 10 թվային դասեր, Գաուսյան խառնուրդ մոդելի կոմպոնենտների թիվը կսահմանենք 10: Նմանատիպ խմբավորման մոտեցումները կարող են օրինակ օգտակար լինել հասկանալու համար տվյալների մեջ եղած աղմուկը: 15 PCA կոմպոնենտով ստացված արդյունքում նկատում ենք որ, 7 և 9 թվերի զույգերը խմբաբոլակ են 2-րդ և 5-րդ դասերում, ինչը նշանակում է, որ PCA կիրառելուց հետո դրանց մեջ կա բավականին նմանություն, իսկ մեր կառուցած GMM մոդելը նմանությունը չի կարողացել ճշտգրիտ տարբերակել: Մնացած թվերի դեպքում արդյունքը բավականին գոհացուցիչ է: Վերջնական ունեցանք 91.98% համընկնում:


cluster\label	0	1	2	3	4	5	6	7	8	9
0	6901	0	0	0	0	0	0	0	0	0
1	0	0	6982	0	0	0	0	0	0	0
2	0	0	0	0	0	0	0	2194	9	3878
3	2	310	8	7141	5	2	0	0	0	0
4	0	7567	0	0	0	0	0	0	0	0
5	0	0	0	0	1	0	0	5099	6	3080
6	0	0	0	0	6818	0	0	0	0	0
7	0	0	0	0	0	0	6876	0	0	0
8	0	0	0	0	0	6311	0	0	0	0
9	0	0	0	0	0	0	0	0	6810	0

Փորձենք նաև կառուցել մոդել, որը կկատարի classification տվյալների համար: Կառուցենք 10 առանձին Գաուսյան խառնուրդ մոդելներ յուրաքանչյուր թվի համար: Նկատենք, որ այս մոտեցման ժամանակ label պյունը ուղիղ մասնակցություն չի ունենա ուսուցման ընթացքում: հետագայում անհայտ label -ով նկարը կպատկանի այն խմբին, որի մոդելը կտա ամենամեծ հավանականությունը: Նախքան ուսուցման գործընթացը, տվյալների մշակումը պարտադիր է: Այս մոտեցման շնորհիվ կարողացանք ստանալ ճշգրիտ կանխատեսումներ :

PCA_n_components	GMM_n_components	Accuracy
50	3	0.9698
50	5	0.9724
50	10	0.9771
50	15	0.9783
100	3	0.9583
100	5	0.9627
100	10	0.9648
100	15	0.9605
150	3	0.9408
150	5	0.9516
150	10	0.9513
150	15	0.9467

Այս աղյուսակը ներկայացնում է մեր ալգորիթմի տարբեր արդյունքները՝ PCA և GMM տարբեր բաղադրիչներով: Լավագույն արդյունքը ստացել ենք PCA-ի 50 և GMM-ի 15 բաղադրիչներով: Նկատում ենք, որ PCA-ի բաղադրիչների մեծացման հետ մոդելի կատարողականությունը վատանում է:

Լավագույն հիպերպարամետրերի համար գծագրել ենք confusion մատրիցը, և ընդհանուր արդյունքը բավականին գոհացուցիչ է:



Համեմատելու համար մեր մոդելի արդյունքները՝ փորձեցինք նաև ուսուցանել այլ մոդելներ, և ընդհանուր առմամբ՝ SVM և K-NN ալգորիթմները ունեն նույն ճշգրտությունը, ինչ մեր մոդելը:

Աղբյուրներ՝

- Pattern recognition and machine learning(M. bishop) - 423-448 էջեր
- The Elements of Statistical Learning:Data Mining,Inference and Prediction(Springer series in Statistics) -272-278 էջեր
- Հոդվածի բանաձևերի մանրամասն ստացումները,ինչպես նաև Գաուսյան խառնուրդների EM-ալգորիթմից K-means դուրս բերումը գրվել է՝ հիմնվելով հավանականությունների տեսություն,մաթեմատիկական անալիզ դասընթացներից ունեցած գիտելիքների վրա:

Ինչպես նաև աշխատանքի կատարման ընթացքում հայտնաբերել ենք վրիպում
 Pattern recognition and machine learning(M. bishop) գրքում:

$$\lim_{\sigma \rightarrow 0} E(L(\theta; X, \Delta) | \theta^{old}, X = y) = -\frac{1}{2} \sum_{k=1}^N (1 - r_k) |x_k - \mu_2|^2 - \frac{1}{2} \sum_{k=1}^N r_k |x_k - \mu_2|^2 + const$$

Փոխարենը պետք է լիներ՝

$$\lim_{\sigma \rightarrow 0} \sigma^2 E(L(\theta; X, \Delta) | \theta^{old}, X = y) = -\frac{1}{2} \sum_{k=1}^N (1 - r_k) |x_k - \mu_2|^2 - \frac{1}{2} \sum_{k=1}^N r_k |x_k - \mu_2|^2 + const$$