

EM Algorithm

Հիմնական գաղափարներ, մաթեմատիկական հիմունքներ
և կիրառություն

Բովանդակություն

- ▶ EM ալգորիթմի ներածություն
- ▶ EM ալգորիթմը Գաուսյան խառնուրդի մոդելում
- ▶ Մաթեմատիկական հասկացությունները օրինակի միջոցով
- ▶ K-Means-ի և EM-ի կապը
- ▶ Կիրառություն

Խառնուրդի մոդելներ

- Դիտարկումներ

- $K = 2$ գաուսյաններ անհայտ պարամետրերով

Խառնուրդի մոդելներ

- Դիտարկումներ

-K = 2 գաուսյաններ անհայտ պարամետրերով

- գիտենք դիտարկման աղբյուրը



Խառնուրդի մոդելներ

- Դիտարկումներ

-K = 2 գաուսյաններ անհայտ պարամետրերով

$$\mu_b = \frac{x_1 + x_2 + \dots + x_{nb}}{n_b}$$

- գիտենք դիտարկման աղբյուրը



Խառնուրդի մոդելներ

- Դիտարկումներ

-K = 2 գաուսյաններ անհայտ պարամետրերով

$$\mu_b = \frac{x_1 + x_2 + \dots + x_{nb}}{n_b}$$

$$\sigma_b^2 = \frac{(x_1 - \mu_b)^2 + (x_2 - \mu_b)^2 + \dots + (x_n - \mu_b)^2}{n_b}$$

- գիտենք դիտարկման աղբյուրը



Խառնուրդի մոդելներ


- Դիտարկումներ

-K = 2 գաուսյաններ անհայտ պարամետրերով

$$\mu_b = \frac{x_1 + x_2 + \dots + x_{nb}}{n_b}$$

$$\sigma_b^2 = \frac{(x_1 - \mu_b)^2 + (x_2 - \mu_b)^2 + \dots + (x_n - \mu_b)^2}{n_b}$$

- գիտենք դիտարկման աղբյուրը



Խառնուրդի մոդելներ

- Դիտարկումներ


-K = 2 գաուսյաններ անհայտ պարամետրերով

$$\mu_b = \frac{x_1 + x_2 + \dots + x_{nb}}{n_b}$$

$$\sigma_b^2 = \frac{(x_1 - \mu_b)^2 + (x_2 - \mu_b)^2 + \dots + (x_n - \mu_b)^2}{n_b}$$

- գիտենք դիտարկման աղբյուրը

- գիտենք պարամետրերը



Խառնուրդի մոդելներ


- Դիտարկումներ

-K = 2 գաուսյաններ անհայտ պարամետրերով


$$\mu_b = \frac{x_1 + x_2 + \dots + x_{nb}}{n_b}$$

$$\sigma_b^2 = \frac{(x_1 - \mu_b)^2 + (x_2 - \mu_b)^2 + \dots + (x_n - \mu_b)^2}{n_b}$$

- գիտենք դիտարկման աղբյուրը



- գիտենք պարամետրերը



Խառնուրդի մոդելներ


- Դիտարկումներ

-K = 2 գաուսյաններ անհայտ պարամետրերով

$$\mu_b = \frac{x_1 + x_2 + \dots + x_{nb}}{n_b}$$

$$\sigma_b^2 = \frac{(x_1 - \mu_b)^2 + (x_2 - \mu_b)^2 + \dots + (x_n - \mu_b)^2}{n_b}$$


- գիտենք դիտարկման աղբյուրը



- գիտենք պարամետրերը

$$b_i = p(b | x_i) = \frac{p(x_i | b)p(b)}{p(x_i | b)p(b) + p(x_i | a)p(a)}$$

$$p(x_i | b) = \frac{1}{\sqrt{(2\pi\sigma_b^2)}} \exp - \left(\frac{(x_i - \mu_b)^2}{(2 * \sigma_b^2)} \right)$$



Դիցուք $X = (X_1, \dots, X_N)$ և $Z = (Z_1, \dots, Z_M)$

Նպատակն է գտնել $P(X|\theta)$ ճշմարտանմանության ֆունկցիայի մաքսիմումը:

Դիտարկենք՝

$$\ln p(X|\theta) = \ln \left[\sum_Z p(X, Z|\theta) \right]$$

Դիցուք $X = (X_1, \dots, X_N)$ և $Z = (Z_1, \dots, Z_M)$

նպատակն է գտնել $P(X|\theta)$ ճշմարտանմանության ֆունկցիայի մաքսիմումը:

Դիտարկենք՝

$$\ln p(X|\theta) = \ln \left[\sum_Z p(X, Z|\theta) \right]$$

EM ալգորիթմի ընթացակարգը

► **Ինիցիալիզացնել** - սկսում ենք պարամետրերի նախնական արժեքներից՝ $\theta^{(\text{old})}$

► **Միջինացում (E) քայլ** - բացակայող տվյալները գնահատվում են ընթացիկ պարամետրերի արժեքներով

$$p(Z | x, \theta^{(\text{old})})$$

► **Մաքսիմալացում (M) քայլ** - Q-ֆունկցիայի կառուցում, պարամետրերի թարմացում


$$Q(\theta | \theta^{(\text{old})}) = \mathbb{E}(\ln p(X, Z | \theta) | x, \theta^{(\text{old})}) = \sum_Z p(Z | x, \theta^{(\text{old})}) \ln p(X, Z | \theta)$$

$$\theta^{\text{new}} = \arg \max_{\theta} \left(Q(\theta | \theta^{\text{old}}) \right)$$

► **Իտերացիա**- կրկնել E և M քայլերը մինչև նախապես սահմանված շեմից ցածր լինելը:

$$\theta^{\text{old}} \leftarrow \theta^{\text{new}}$$

EM ալգորիթմի ընթացակարգը



Մաթեմատիկական հասկացությունները օրինակի միջոցով


Նախ եկեք գեներացնենք տվյալներ R լեզվով

```
# Generate binomial samples
binomial_samples <- rbinom(10000, size = 1, prob = 0.2)


# Initialize an empty vector to store the generated values
datapoints <- numeric(length(binomial_samples))

# Generate values based on binomial samples
for (i in seq_along(binomial_samples)) {
  if (binomial_samples[i] == 1) {
    datapoints[i] <- rnorm(1, mean = -12, sd = 3)
  } else {
    datapoints[i] <- rnorm(1, mean = 2, sd = 1)
  }
}
```


Histogram and Density Plot



Histogram and Density Plot



Ենթադրենք որ, նորմալ բաշխումների
միջինների ու վարիացիաների
ինֆորմացիան կորցրել ենք

- Ուստի մենք կմոդելավորենք Y -ը որպես երկու նորմալ բաշխումների խառնուրդ

$$Y_1 \sim N(\mu_1, \sigma_1^2)$$

$$Y_2 \sim N(\mu_2, \sigma_2^2)$$

$$Y = (1 - \Delta)Y_1 + \Delta Y_2, \quad \Delta \in \{0,1\} \text{ and } P(\Delta = 1) = p$$

- Ուստի մենք կմոդելավորենք Y -ը որպես երկու նորմալ բաշխումների խառնուրդ

$$Y_1 \sim N(\mu_1, \sigma_1^2)$$

$$Y_2 \sim N(\mu_2, \sigma_2^2)$$

$$Y = (1 - \Delta)Y_1 + \Delta Y_2, \quad \Delta \in \{0,1\} \text{ and } P(\Delta = 1) = p$$

- Հիմա ենթադրենք, որ մենք ցանկանում ենք առավելագույն հավանականությամբ այս մոդելը համապատասխանեցնել մեր տվյալներին:

- Ուստի մենք կմոդելավորենք Y -ը որպես երկու նորմալ բաշխումների խառնուրդ

$$Y_1 \sim N(\mu_1, \sigma_1^2)$$

$$Y_2 \sim N(\mu_2, \sigma_2^2)$$

$$Y = (1 - \Delta)Y_1 + \Delta Y_2, \quad \Delta \in \{0,1\} \text{ and } P(\Delta = 1) = p$$

- Հիմա ենթադրենք, որ մենք ցանկանում ենք առավելագույն հավանականությամբ այս մոդելը համապատասխանեցնել մեր տվյալներին:

$$\theta = (p, \theta_1, \theta_2) = (p, \mu_1, \sigma_1^2, \mu_2, \sigma_2^2)$$

- Դիտարկենք N դեպքերի վրա հիմնված log-likelihood -ը

$$l(\theta, x) = \sum_{i=1}^N \log \left[(1 - p) \cdot \phi_{\theta_1}(y_i) + p \cdot \phi_{\theta_2}(y_i) \right]$$

- Դիտարկենք N դեպքերի վրա հիմնված log-likelihood -ը

$$l(\theta, x) = \sum_{i=1}^N \log \left[(1 - p) \cdot \phi_{\theta_1}(y_i) + p \cdot \phi_{\theta_2}(y_i) \right]$$

- Ենթադրենք, որ մենք գիտեինք Δ_i -ի արժեքները

- Դիտարկենք N դեպքերի վրա հիմնված log-likelihood -ը

$$l(\theta, x) = \sum_{i=1}^N \log \left[(1 - p) \cdot \phi_{\theta_1}(y_i) + p \cdot \phi_{\theta_2}(y_i) \right]$$

- Ենթադրենք, որ մենք գիտեինք Δ_i -ի արժեքները

$$L(\theta, x, \Delta) = \sum_{k=1}^N \left[(1 - \Delta_k) \cdot \log(\phi_{\theta_1}(y_k)) + \Delta_k \cdot \log(\phi_{\theta_2}(y_k)) \right] + \sum_{k=1}^N \left[(1 - \Delta_k) \cdot \log(1 - p) + \Delta_k \cdot \log(p) \right]$$

Այս դեպքում մենք հեշտությամբ կարող ենք գտնել պարամետրերը

- Դիտարկենք N դեպքերի վրա հիմնված log-likelihood -ը

$$l(\theta, x) = \sum_{i=1}^N \log \left[(1 - p) \cdot \phi_{\theta_1}(y_i) + p \cdot \phi_{\theta_2}(y_i) \right]$$

- Ենթադրենք, որ մենք գիտեինք Δ_i -ի արժեքները

$$L(\theta, x, \Delta) = \sum_{k=1}^N \left[(1 - \Delta_k) \cdot \log(\phi_{\theta_1}(y_k)) + \Delta_k \cdot \log(\phi_{\theta_2}(y_k)) \right] + \sum_{k=1}^N \left[(1 - \Delta_k) \cdot \log(1 - p) + \Delta_k \cdot \log(p) \right]$$

Այս դեպքում մենք հեշտությամբ կարող ենք գտնել պարամետրերը

- Քանի որ Δ_i -ի արժեքներն իրականում անհայտ են, կշարունակենք այլ եղանակով՝ փոխարինելով յուրաքանչյուր Δ_i -ին իր մաթեմատիկական սպասման արժեքով :

$$\gamma_i(\theta) = \mathbb{E}(\Delta_i \mid \theta, X) = \sum_{k=0}^1 k P(\Delta_i = k \mid \theta, X) = \frac{p \phi_{\theta_2}(y_i)}{(1 - p) \phi_{\theta_1}(y_i) + p \phi_{\theta_2}(y_i)}$$

- Դիտարկենք N դեպքերի վրա հիմնված log-likelihood -ը

$$l(\theta, x) = \sum_{i=1}^N \log \left[(1 - p) \cdot \phi_{\theta_1}(y_i) + p \cdot \phi_{\theta_2}(y_i) \right]$$

- Ենթադրենք, որ մենք գիտեինք Δ_i -ի արժեքները

$$L(\theta, x, \Delta) = \sum_{k=1}^N \left[(1 - \Delta_k) \cdot \log(\phi_{\theta_1}(y_k)) + \Delta_k \cdot \log(\phi_{\theta_2}(y_k)) \right] + \sum_{k=1}^N \left[(1 - \Delta_k) \cdot \log(1 - p) + \Delta_k \cdot \log(p) \right]$$

Այս դեպքում մենք հեշտությամբ կարող ենք գտնել պարամետրերը

- Քանի որ Δ_i -ի արժեքներն իրականում անհայտ են, կշարունակենք այլ եղանակով՝ փոխարինելով յուրաքանչյուր Δ_i -ին իր մաթեմատիկական սպասման արժեքով :

$$\gamma_i(\theta) = \mathbb{E}(\Delta_i \mid \theta, X) = \sum_{k=0}^1 k P(\Delta_i = k \mid \theta, X) = \frac{p \phi_{\theta_2}(y_i)}{(1 - p) \phi_{\theta_1}(y_i) + p \phi_{\theta_2}(y_i)}$$

- Հիմա կառուցենք $Q(\theta, \theta^{(\text{old})})$ ֆունկցիան մաքսիմալացման քայլի համար:

$$Q(\theta, \theta^{(\text{old})}) = \mathbb{E}(L(\theta; X, \Delta) \mid \theta^{(\text{old})}, X = y) = \sum_{k=1}^N (1 - \gamma_k(\theta^{(\text{old})})) (\log(\phi_{\theta_1}(y_k)) + \log(1 - p)) + \sum_{k=1}^N \gamma_k(\theta^{(\text{old})}) (\log(\phi_{\theta_2}(y_k)) + \log(p))$$

- Վերջապես, եթե մենք հաշվենք Q ֆունկցիայի ածանցյալները ըստ π -ի, μ_1 -ի, σ_1 -ի, μ_2 -ի σ_2 -ի ապա կունենանք այս գնահատականները

$$\hat{\mu}_1 = \frac{\sum_{k=1}^N (1 - \gamma_k(\theta^{\text{old}})) y_k}{\sum_{k=1}^N (1 - \gamma_k(\theta^{\text{old}}))}$$

$$\hat{\mu}_2 = \frac{\sum_{i=1}^N \hat{\gamma}_i y_i}{\sum_{i=1}^N \hat{\gamma}_i}$$

$$\hat{\sigma}_1^2 = \frac{\sum_{i=1}^N (1 - \hat{\gamma}_i) (y_i - \hat{\mu}_1)^2}{\sum_{i=1}^N (1 - \hat{\gamma}_i)}$$

$$\hat{\sigma}_2^2 = \frac{\sum_{i=1}^N \hat{\gamma}_i (y_i - \hat{\mu}_2)^2}{\sum_{i=1}^N \hat{\gamma}_i}$$

$$\hat{p} = \frac{\sum_{k=1}^N (\gamma(\theta^{\text{old}}))}{N}$$

K-means VS EM

K-means ալգորիթմի ու Գաուսի խառնուրդների EM ալգորիթմի միջև կա մոտ նմանություն

- դիտարկենք հետևյալ r ֆունկցիան՝

$$r_i = \begin{cases} 1, & \text{if } |y_i - \mu_2|^2 < |y_i - \mu_1|^2 \\ 0, & \text{if } |y_i - \mu_2|^2 > |y_i - \mu_1|^2 \end{cases}$$

K-means VS EM

K-means ալգորիթմի ու Գաուսի խառնուրդների EM ալգորիթմի միջև կա մոտ նմանություն

- դիտարկենք հետևյալ r ֆունկցիան՝

$$r_i = \begin{cases} 1, & \text{if } |y_i - \mu_2|^2 < |y_i - \mu_1|^2 \\ 0, & \text{if } |y_i - \mu_2|^2 > |y_i - \mu_1|^2 \end{cases}$$

- Եթե $|y_i - \mu_2|^2 < |y_i - \mu_1|^2$

$$\lim_{\sigma^2 \rightarrow 0} \gamma(\theta) = \lim_{\sigma^2 \rightarrow 0} \frac{p\varphi_{\theta_2}(y_i)P(\theta, X)}{(1-p)\varphi_{\theta_1}(y_i) + p\varphi_{\theta_2}(y_i)} = 1$$

- Եթե $|y_i - \mu_2|^2 > |y_i - \mu_1|^2$

$$\lim_{\sigma^2 \rightarrow 0} \gamma(\theta) = \lim_{\sigma^2 \rightarrow 0} \frac{p\varphi_{\theta_2}(y_i)P(\theta, X)}{(1-p)\varphi_{\theta_1}(y_i) + p\varphi_{\theta_2}(y_i)} = 0$$

K-means VS EM

K-means ալգորիթմի ու Գաուսի խառնուրդների EM ալգորիթմի միջև կա մոտ նմանություն

- դիտարկենք հետևյալ r ֆունկցիան՝

$$r_i = \begin{cases} 1, & \text{if } |y_i - \mu_2|^2 < |y_i - \mu_1|^2 \\ 0, & \text{if } |y_i - \mu_2|^2 > |y_i - \mu_1|^2 \end{cases}$$

- Եթե $|y_i - \mu_2|^2 < |y_i - \mu_1|^2$

$$\lim_{\sigma^2 \rightarrow 0} \gamma(\theta) = \lim_{\sigma^2 \rightarrow 0} \frac{p\varphi_{\theta_2}(y_i)}{(1-p)\varphi_{\theta_1}(y_i) + p\varphi_{\theta_2}(y_i)} = 1$$

- Եթե $|y_i - \mu_2|^2 > |y_i - \mu_1|^2$

$$\lim_{\sigma^2 \rightarrow 0} \gamma(\theta) = \lim_{\sigma^2 \rightarrow 0} \frac{p\varphi_{\theta_2}(y_i)}{(1-p)\varphi_{\theta_1}(y_i) + p\varphi_{\theta_2}(y_i)} = 0$$

Այսպիսով՝

$$\lim_{\sigma^2 \rightarrow 0} \sigma^2 \cdot \mathbb{E}(L(\theta; X, \Delta) \mid \theta^{(\text{old})}, X = y) = -\frac{1}{2} \sum_{i=1}^N (1 - r_i) |x - \mu_1|^2 - \frac{1}{2} \sum_{i=1}^N r_i |x - \mu_2|^2 + \text{const}$$

K-means VS EM

K-Means:

- Յուրաքանչյուր կետ վերագրում է ամենամոտ կլաստերին՝ ելնելով էվկլիդեսյան հեռավորությունից:

EM:

- Հաշվի է առնում, թե որքան հավանական է յուրաքանչյուր կլաստերին պատկանելու հավանականությունը:

K-means VS EM

K-Means:

- Յուրաքանչյուր կետ վերագրում է ամենամոտ կլաստերին՝ ելնելով էվկլիդեսյան հեռավորությունից:
- Ստեղծում է ֆիքսված ձևերով շրջանաձև կլաստերներ:

EM:

- Հաշվի է առնում, թե որքան հավանական է յուրաքանչյուր կլաստերին պատկանելու հավանականությունը:
- Թույլ է տալիս տարբեր ձևերի կլաստերներ (էլիպսաձև)

K-means VS EM

K-Means:

- Յուրաքանչյուր կետ վերագրում է ամենամոտ կլաստերին՝ ելնելով էվկլիդեսյան հեռավորությունից:
- Ստեղծում է ֆիքսված ձևերով շրջանաձև կլաստերներ:
- Բոլոր կլաստերներն ունեն հավասար շեղումներ:

EM:

- Հաշվի է առնում, թե որքան հավանական է յուրաքանչյուր կլաստերին պատկանելու հավանականությունը:
- Թույլ է տալիս տարբեր ձևերի կլաստերներ (էլիպսաձև)
- Կարող է մշակել տարբեր չափերի կլաստերներ:

Գառուսյան խառնուրդ մոդելի կիրառումը MNIST տվյալների վրա



Գառույան խառնուրդ մոդելի կիրառումը MNIST տվյալների վրա


Սկզբում կոփտարկենք clustering-ի խնդիր հասկանալու համար տվյալների մեջ եղած աղմուկը

cluster\label	0	1	2	3	4	5	6	7	8	9
0	6901	0	0	0	0	0	0	0	0	0
1	0	0	6982	0	0	0	0	0	0	0
2	0	0	0	0	0	0	0	2194	9	3878
3	2	310	8	7141	5	2	0	0	0	0
4	0	7567	0	0	0	0	0	0	0	0
5	0	0	0	0	1	0	0	5099	6	3080
6	0	0	0	0	6818	0	0	0	0	0
7	0	0	0	0	0	0	6876	0	0	0
8	0	0	0	0	0	6311	0	0	0	0
9	0	0	0	0	0	0	0	0	6810	0


Գառուսյան խառնուրդ մոդելի կիրառումը MNIST տվյալների վրա

PCA_n_components	GMM_n_components	Accuracy
50	3	0.9694
50	5	0.9713
50	10	0.9749
50	15	0.9766
100	3	0.9575
100	5	0.9621
100	10	0.9635
100	15	0.963
150	3	0.9439
150	5	0.9521
150	10	0.9495
150	15	0.9485

Գաուսյան խառնուրդ մոդելի կիրառումը MNIST տվյալների վրա



Results for Gaussian Mixture Model (GMM): 0.976



Results for k-Nearest Neighbors: 0.9688

Շնորհակալություն ուշադրության համար!